

חיזוי תקלות בדיסקים קשיחים — סיכום פרויקט

Predictive Maintenance על נתוני SMART · שני datasets (Toshiba + Backblaze) · השוואת DNN מול XGBoost · מסמך פנימי

1. מה בעצם עשינו כאן

לקחנו טלמטריה יומית של דיסקים קשיחים (SMART attributes) — מדדים שהדיסק מדווח על עצמו כל יום: טמפרטורה, שעות עבודה, סקטורים פגומים וכו' וניסינו לענות על שתי שאלות:

- שאלה 1 — סיווג (classification):** "האם הדיסק הזה הולך להיכשל ב-30 הימים הקרובים?" תשובה: כן / לא.
- שאלה 2 — רגרסיה (RUL, Remaining Useful Life):** "כמה ימים נשארו לדיסק הזה עד שהוא מת?" תשובה: מספר ימים.

כל שאלה נפתרה בשני מודלים על **אותם בדיק** features, splits ומטריקות — (PyTorch) DNN מול XGBoost — כדי שההשוואה תהיה אמיתית ולא תחושת בטן. בנוסף בנינו גרסה שלישית: מודל CNN שמקבל את רצף 90 הימים הגולמי במקום features שחישבנו ידנית.

2. הקלט (Input) — מאיפה הנתונים

מקור	מה זה	גודל	הערה
Toshiba המוקד העיקרי	Export מקומי — 105 קבצי Excel	3,224,289 drive-days דיסקים · 14 משפחות 5,589 2024-01 → 2026-03	2,746 אירועי כשל. המרנו פעם אחת ל-parquet יחיד: 0.7GB → 34MB, נטען בשנייה במקום 5 דקות
Backblaze	רבעונים ציבוריים שמורידים מהרשת, דיסקי Seagate בלבד	שורות 20,499,653 positive rate 0.079%	ה-baseline שממנו התחלנו, ומשמש להשוואה בין יצרנים

נקודה חשובה: רשימת ה-features של Seagate לא עוברת ל-Toshiba. שלושה מדדים מרכזיים (smart_187, 188, 241) פשוט לא מדווחים בכלל ע"י Toshiba, ורוב מה שכן מדווח קבוע או ריק. לכן בחרנו מחדש מתוך הנתונים עצמם: **16 מדדי SMART** רלוונטיים (11 שכל 14 המשפחות מדווחות + 5 שחסרים בשתי משפחות ה-"EY").

3. איך בנינו את ה-Features — חלון של 90 יום

כל תחזית מתבססת על **90 הימים האחרונים** של הדיסק, לא על קריאה בודדת. עשינו את זה בשתי גישות:

גישה א' — features מחושבים ידנית

Dataset_Toshiba_Comparison.ipynb

- הערך הנוכחי של כל מדד
 - $_d7$ / $_d30$ / $_d90$ — כמה השתנה ב-7/30/90 יום
 - $_max90$ / $_std90$ / $_mean90$ — ממוצע, תנודתיות, והערך הכי גרוע בחלון
 - + גיל הדיסק, קיבולת, one-hot של הדגם
- סה"כ **129** features · 2,732,751 שורות

גישה ב' — הרצף הגולמי

Dataset_Toshiba_Window90.ipynb

- בלי חישוב ידני — המודל מקבל טנזור (ימים $\times$ 33 ערוצים 90)
 - 33 ערוצים = 16 ערכים + 16 הפרשי 7 ימים + ערוץ observed שמסמן איפה הנתון אמיתי ואיפה הושלם
 - ה-CNN לומד לבד איזה סיכום מעניין אותו
- סה"כ **20,193** חלונות ב-test

שורות בלי חלון מלא אמיתי **נזרקו** ולא הושלמו בחציון (2.73M מתוך 3.22M שרדו). ה-split הוא GroupShuffleSplit לפי דיסק — דיסק אחד לעולם לא מופיע גם ב-train וגם ב-test, אחרת היינו מרמים את עצמנו. גם ה-notebook מריץ leakage guard שמוודא שעמודת ה-failure לא דלפה לתוך ה-X.

4. איך מודדים — ולמה Accuracy לא רלוונטי

רק 2.5% מהשורות הן "דיסק בסכנה", אז מודל שאומר "הכל בסדר" תמיד מקבל 97.5% accuracy ואפס תועלת. לכן המטריקה המובילה היא **PR-AUC** (איכות הדירוג כשיש חוסר איזון) ו-**Precision@K** (מתוך K הדיסקים הכי חשודים, כמה באמת נכשלים). ה-threshold מכוון על ה-validation בלבד, ואז מוקפא ומופעל פעם אחת על ה-test.

5. התוצאות (Output)

Toshiba — סיווג "יכשל תוך 30 יום" · 563,629 129 features שורות test

מודל	ROC-AUC	★ PR-AUC	Precision	Recall	F1	Threshold
DNN (PyTorch)	0.7944	0.1768	0.275	0.229	0.250	0.92
XGBoost ✓ המנצח	0.8304	0.2353	0.297	0.304	0.300	0.58

★ נקודת ייחוס: ניחוש אקראי נותן PR-AUC של 0.024. כלומר XGBoost מדרג טוב פי **10~** מאקראי. XGBoost גם מתאמן בפחות מדקה במקום עשרות דקות, ונותן feature importances בחינם.

ב. מה זה אומר בפועל — Precision@K (XGBoost, Toshiba)

21x Lift מעל אקראי בראש הרשימה	13% מ-10% העליונים (56,362) · תופס 53% מהכשלים	36% מ-1% העליונים (5,636) · תופס 15% מהכשלים	50% מ-0.1% הכי חשודים — כל דיסק שני באמת נכשל (563 דיסקים)
---	---	---	--

זו השורה התחתונה העסקית: טכנאי לא בודק את כל הצי, הוא עובד עם תור. אם הוא בודק את 563 הדיסקים הכי חשודים — כל דיסק שני שהוא פותח באמת בדרך למות. באקראי זה היה 1 מכל 42.

ג. Toshiba — מודל CNN על רצף 90 הימים הגולמי

מודל	PR-AUC	ROC-AUC	Precision	Recall	F1	Confusion (TP/FP/FN/TN)
1D-CNN (dilated)	0.3433	0.8733	0.388	0.412	0.400	220 / 347 / 314 / 19,312

אימון של 3.3 דקות על CPU, 8 epochs, base rate 2.64%. **שים לב — אי אפשר להשוות ישירות לטבלה א':** שם היחידה היא drive-day ופה חלון של 90 יום, והתייג פה מחמיר יותר (הכשל חייב ליפול בתוך החלון, ולכן מודל שמזהיר שבוע מוקדם מדי דווקא נענש).

T. RUL — כמה ימים נשארו · 136,102 · Toshiba שורות מ-2,374 דיסקים שנכשלו

מודל	MAE (ימים)	RMSE (ימים)	R ²	פרשנות
DNN	15.08	17.86	-0.032	R ² שלילי = גרוע יותר מלנחש את הממוצע
XGBoost ✓	14.22	16.79	0.088	טוב יותר, אבל עדיין חלש מאוד

המסקנה הכנה: ה-RUL עובד גרוע. טעות ממוצעת של 14 יום בתוך חלון של 0-60 יום היא כמעט חסרת ערך תפעולי. **הסייוג עובד, הרגרסיה לא.**

ה. **Backblaze (Seagate), horizon 10 יום, 4.1M שורות test** — DNN: ROC-AUC 0.898 / PR-AUC 0.152 / F1 0.266 — XGBoost: ROC-AUC 0.904 / PR-AUC 0.156 / F1 0.254. ה-base rate שם נמוך פי 30 (0.079%), ולכן ה-PR-AUC נמוך יותר למרות ROC-AUC גבוה יותר — עוד סיבה לא להסתכל על ROC-AUC לבד.

ו. **פילוח לפי משפחת דיסקים** — הביצועים משתנים מאוד: MG10ACA20TE מגיע ל-PR-AUC 0.425, MG08ACA16TE רק 0.123. אימון על כל המשפחות יחד (pooled) עדיף מעט על אימון נפרד לכל משפחה, אבל **המודל לא מכיל למשפחה שלא ראה**: ב-leave-one-out ה-PR-AUC צונח (0.128 → 0.284). כלומר דגם חדש בצי מחייב אימון מחדש.

6. הדבר שהכי השפיע — באג ששווה לזכור

תיקנו את חוסר האיזון פעמיים בטעות. ה-DNN גם דגם batches מאוזנים עם WeightedRandomSampler וגם הפעיל pos_weight=37 על ה-loss. ה-XGBoost קיבל scale_pos_weight ביחס הגולמי, מה שגרם ל-PR-AUC להגיע לשיא אחרי 12~ עצים ואז לרדת — וה-early stopping החזיר מודל של 12 עצים בלבד. **למה זה מזיק:** כל המטריקות פה מודדות זירוף, ולנפח את המחלקה החיובית רק מעוות את הגרדיאנט בלי לשפר את הדירוג. היום ה-notebook **מודד** את אסטרטגיית האיזון על ה-validation במקום להניח אותה (סעיף 10 ל-DNN, 16b ל-XGBoost). זה השינוי היחיד שהזיז את המספרים הכי הרבה.

7. מגבלות שחייבים לזכור

- ה-Toshiba export-cohort **הוא לא הצי המלא** — כל דיסק שנכשל + מדגם מותאם של בריאים. מטריקות דירוג (PR-AUC, Precision@K) תקפות לפרודקשן; אחוז הכשלים המוחלט **לא**.
- שלוש משפחות (MD04ABA400V, HDWE160, MG11ACA16TE) בלי אף כשל — תורמות רק דוגמאות שליליות.
- חלון 90 יום עולה בכיסוי: 90 הימים הראשונים של דיסק לא ניתנים לניקוד — וזו בדיוק תקופת תמותת התינוקות.
- מודל ה-RUL רואה רק דיסקים שנכשלו, ולכן הפלט שלו משמעותי רק לדיסק שהמסווג כבר סימן.

8. מפת קבצים — איפה מה

- Dataset_Toshiba_Comparison.ipynb — ה-notebook המרכזי: RUL, DNN + XGBoost, 129 features, EDA, פילוח לפי משפחה
- Dataset_Toshiba_Window90.ipynb — גרסת ה-CNN sequence על 90 ימים גולמיים · Dataset_backblaze_*.ipynb — אותם שני הדברים על Backblaze/Seagate
- scripts/build_toshiba_parquet.py — 105 קבצי parquet → xlsx יחיד (רצים פעם אחת) · scripts/backblaze_window_pipeline.py — כל לוגיקת ה-windowing והמודלים שה-notebooks מייבאים
- models/ — 6 מודלים מאומנים + preprocessing config לכל אחד · results/ — toshiba_per_model_metrics.csv, toshiba_cross_model_comparison.csv

9. הצעד הבא

להשוות את שלוש הארכיטקטורות (CNN / GRU / Transformer) על אותם splits · לשחק עם horizon_days (כרגע 0 בגרסת החלון — שינוי של שורה אחת שיקרב את המשימה למה שמפעיל באמת רוצה) · לבדוק ב-ablation אם ערוץ ה-observed באמת תורם · ולהריץ על הצי המלא במקום ה-cohort כדי לתקן את עיוות ה-base-rate.